

只做微调的可用 ASR 模型与数据集深度调研报告

执行摘要

本报告聚焦“**不从头训练、只在现有预训练模型上做微调**”的 ASR (Automatic Speech Recognition) 模型与公开数据集，并**优先以用户提供的《SpeakSure++》PDF 中的需求与约束**作为筛选依据：系统当前在 ASR Agent 中明确采用 **Whisper** 进行语音转写并输出**带时间戳文本**（用户 PDF，第3页），并规划未来支持**实时分析**（用户 PDF，第12页）。在 PDF 未明确给出的假设（硬件预算、数据规模、部署方式、是否必须离线/端侧、是否必须流式等）一律标注为“未指定”，并给出基于常见硬件（A100/V100/RTX4090）的可复用估算方法。

综合准确率、时间戳能力、工程可用性与社区生态，最适配“SpeakSure++ 现状（Whisper 已集成）+ 未来可能实时化”的微调路线通常分成两类：

其一是以 **Whisper 系列（Transformers/PEFT）** 为中心，用较小代价在中文/业务域数据上做 LoRA/Adapter/全参微调，并维持与现有链路一致的输出形式；Whisper 的模型规模与版本、以及官方/社区给出的微调设置与 CER/WER 结果，已能直接支撑“可落地”的微调与评测闭环。¹

其二是为未来“低延迟/流式”做准备，选用原生支持流式/分块推理的工具链（如 WeNet、NVIDIA NeMo 系列），在中文场景可优先考虑 **WeNet（U2++/Conformer, CTC+Attention/LM 融合）** 与 **FunASR Paraformer（中文、并行解码、可做时间戳与热词增强）**。²

数据集方面，中文微调数据应优先覆盖“干净朗读 + 会话/会议 + 多场景噪声”，以防 SpeakSure++ 在“犹豫/停顿/填充词”相关特征上因训练域偏差产生识别遗漏。推荐组合通常以 **AISHELL-1（干净朗读）** + **WenetSpeech（大规模多域）** + **AliMeeting/AISHELL-4（会议多通道/多说话人）** + **Common Voice zh-CN（众包多口音）** 为主干，并严格审查 CC BY-NC-ND 等非商用/禁止改作许可带来的合规风险。³

PDF 需求、约束与目标提取

与 ASR 直接相关的已明确需求

《SpeakSure++》PDF 对 ASR 组件给出较明确的事实约束：

系统在“ASR Agent”中**使用 Whisper 进行语音转写**，并要求输出**带时间戳的文本**（用户 PDF，第3页）。同时技术栈列举中也包含 Whisper（用户 PDF，第3页）。这些信息意味着：

一是**短期最小改动路径**应优先选择 Whisper 的微调/加速/对齐方案；二是模型与数据集筛选中应把“**可输出/可对齐时间信息**”作为关键维度（PDF 未指定是否必须到词级时间戳，但“带时间戳”是硬需求，粒度未指定）。

与数据形态/评测相关的线索

PDF 的实验设计提到构建了“小规模语音数据”，包含**多个说话人**，并区分“高置信度/低置信度（含犹豫）”，标注为“句子级标签、不确定性来源”；评测指标包含 Accuracy/Precision/Recall（用户 PDF，第8页）。这些信息更多指向 SpeakSure++ 的“不确定性分析”任务，但对 ASR 微调有间接启发：

若 ASR 微调目标包含“更好保留犹豫、填充词、重复”等现象，则训练/验证集应覆盖**会话式语音与含停顿/口头禅**的标注文本（PDF 未指定其标注粒度是否包含这些现象）。

对实时/流式的规划

PDF 在未来工作中明确提出“支持实时分析”（用户PDF，第12页）。这不是当前硬约束，但意味着：模型选型与接口设计最好避免把系统锁死在“只能离线批处理”的推理栈上（例如提前评估是否需要流式 ASR 或分块推理策略），且需要在模型对比中考察“在线/流式推理能力”。

PDF 未指定但会显著影响方案设计的关键信息

以下因素在 PDF 中**未明确**，本报告后续涉及这些内容时均视为“未指定”并给出参考估算：
硬件预算与 GPU 型号、是否必须端侧/离线、是否允许云服务、目标延迟指标（ms）、吞吐目标（RTF/并发流数）、训练数据规模（小时数）、是否存在业务专有词表/热词、是否必须词级时间戳、是否需要说话人分离/多说话人转写（diarization+ASR）。

可微调 ASR 模型对比

本节对“可直接拿来做微调、无需从头训练”的主流 ASR 模型/系列做对比。若某字段在官方材料中未给出，则标为“未指定”。若数字为工程估算，会明确标注“估算（PDF未指定）”。

模型对比表

下表拆成两部分：**A 表侧重训练/微调要素，B 表侧重部署/推理/维护要素**。两表合并覆盖用户要求的全部维度。

模型对比表 A：训练与微调视角

模型/系列	作者/组织	是否在PDF中提及	开源许可（代码/权重）	预训练语料与语言覆盖	架构（CTC/Seq2Seq/Transducer/CTC+LM等）	参数量	支持的微
Whisper（含 large-v3 / turbo 等）	OpenAI ⁴	是（用户PDF，第3页）	MIT（代码；权重随仓库发布，具体条款按仓库/模型卡说明）	多语言 ASR/翻译；Whisper 论文给出规模与架构；large-v3 训练数据为 100万小时弱标注 + 400万小时伪标注（模型卡变更说明）	Seq2Seq Transformer（编码器-解码器）	tiny 39M...large 1550M；turbo 798M	Hugging (run_ PEFT/L
Distil-Whisper（distil-large-v2/v3 等）	Hugging Face ⁶	否	继承 Whisper 的 MIT（模型卡说明）	仅英文 （模型卡明确指出当前仅英语 ASR）；针对长短音频给出相对延迟与 WER 对比表	Seq2Seq Transformer（蒸馏版 Whisper）	distil-large-v2: 756M	Transfo 端（模型

模型/系列	作者/组织	是否在PDF中提及	开源许可（代码/权重）	预训练语料与语言覆盖	架构（CTC/Seq2Seq/Transducer/CTC+LM等）	参数量	支持的微
Wav2Vec2-XLSR-53 (facebook/wav2vec2-large-xlsr-53)	Meta ⁸	否	Apache-2.0 (HF 模型页)	53 语言跨语种预训练；需下游 ASR 监督微调	CTC（常见做法：CTC + 可选外部 LM）	未指定	Transfo encode Adapten
WavLM-Large (microsoft/wavlm-large)	Microsoft ¹⁰	否	CC BY-SA 3.0 Unported (UniSpeech LICENSE；HF 模型卡指向该许可)	HF 模型卡列出预训练数据：Libri-Light 6万小时、GigaSpeech 1 万小时、VoxPopuli 2.4 万小时；主要面向英文；需加 tokenizer 并在标注数据上微调	预训练为 HuBERT 系；下游 ASR 通常做 CTC 头微调（也可结合 LM）	未指定	Transfo head） 微调”由
MMS (facebook/mms-1b / mms-1b-all)	Meta ⁸	否	CC BY-NC 4.0 (HF 模型页)	基座 mms-1b：约 50万小时、1400+语言自监督预训练；mms-1b-all：在 1162 语言上做多语 ASR 适配（模型页说明）	基于 Wav2Vec2 架构；mms-1b-all 使用 adapter 机制做多语转写	1B	Transfo 给出“C MMS”和
Paraformer-large (funasr/Paraformer-large)	FunASR ¹³ （出品方写为阿里达摩院语音团队见模型卡与论文引用）	否	模型：Apache-2.0 (HF 模型卡)；框架代码：MIT；部分预训练权重可能适用单独的 Model License Agreement（仓库提供）	模型卡：基于 6万小时普通话（Mandarin）工业数据训练；强调并行解码带来推理效率提升；提供 ONNX runtime 示例含 quantize 参数	非自回归端到端 ASR（NAR）；并行生成；生态中可扩展时间戳/热词等能力（论文/工具包说明）	未指定	FunASR （推理元

模型/系列	作者/组织	是否在PDF中提及	开源许可（代码/权重）	预训练语料与语言覆盖	架构（CTC/Seq2Seq/Transducer/CTC+LM等）	参数量	支持的微
WeNet (U2++ Conformer 示例)	WeNet ¹⁵	否	Apache-2.0	提供多种预训练模型与两类checkpoint（可继续训练/推理）；中文 recipes（如 aishell）提供 CTC/attention/LM 融合解码结果	典型为 Conformer Encoder + CTC/Attention 两段式（U2++）；可做 CTC+LM、attention rescoring 等	示例模型 (EffiConformer) 在 HF model 卡给出约 48.5M 参数（仅示例，不代表全部）	WeNet sherpa-
Canary-1B-v2 (nvidia/canary-1b-v2)	NVIDIA ¹⁷	否	CC BY 4.0 (HF 模型页)	25 种欧洲语言；强调自动标点/大小写与词/段级时间戳（模型页）；训练数据规模在技术报告中给出（1.7M小时，含 Granary、NeMo ASR Set 3.0 等）	FastConformer Encoder + Transformer Decoder (NeMo 文档)	1B	NeMo (inference)
Nemotron-ASR-Streaming (nemotron-asr-streaming / nemotron-speech-streaming-en-0.6b)	NVIDIA ¹⁷	否	NVIDIA Open Model License Agreement (NIM 模型卡)	英文流式 ASR；训练数据：约25万小时美式英文 (ASRSet) (模型卡)	Cache-Aware FastConformer Encoder + RNNT (Transducer) Decoder；无重叠计算、缓存复用（模型卡）	600M	NeMo/F 亦有对应

说明：表中“微调资源/时间”若未由原始材料明确给出，则标“未指定”或仅基于公开示例给出可复用的估算法；SpeakSure++ PDF 未提供训练环境与预算（未指定）。

模型对比表 B：部署、推理、维护视角

模型/系列	多语言与方言支持	在线/流式推理能力	推理延迟与吞吐	是否支持量化/蒸馏	社区活跃度与维护状态	关键链接（代码/示例）
Whisper	多语言（模型卡列出多语言/多任务；具体覆盖语言数在不同资料中表述不一，PDF未指定）	原生非流式；可用分段/长音频算法；社区提供“更快推理/量化/推理引擎”	faster-whisper 声称同精度下可达 $\sim 4\times$ 更快且更省内存，并支持 8-bit 量化（相对描述）	支持：蒸馏（Distil-Whisper）；量化：faster-whisper、OpenVINO 等生态	极活跃：官方仓库与 Transformers/社区教程成熟	https://github.com/openai/whisper ； https://github.com/SYSTRAN/faster-whisper
Distil-Whisper	英文限定（模型卡）	支持短/长音频转写流程（模型卡目录）；可做分块/推测解码	模型卡给出相对延迟（如 distil-large-v2 相对 latency $\approx 5.8\times$ ，并列短/长 WER）	明确支持 8bit/4bit 量化章节；本身属于蒸馏模型	活跃（HF 发布与训练代码公开）	https://huggingface.co/distil-whisper/distil-large-v2
Wav2Vec2-XLSR	多语言（53 语种预训练）	非原生流式（可分块工程化；未指定）	未指定（取决实现/解码器/批处理）	生态可做量化（HF 提供量化模型树入口，但具体方案未在本报告强行补齐）	活跃（Transformers 官方脚本与大量微调模型）	https://github.com/huggingface/transformers/blob/main/examples/pytorch/speech-recognition/README.md
WavLM	主要英文；面向“全栈语音任务”表征（模型卡）	非原生流式（未指定）	未指定	未指定	活跃（HF 下载量高；但 ASR 需自行构建 tokenizer/头）	https://huggingface.co/microsoft/wavlm-large
MMS	1000+ 语言（模型卡）	非原生流式（未指定）；adapter 多语适配	OpenASR leaderboard 提供 mean WER 与 RTFx 指标（平台口径）	支持 adapter；量化模型树存在（但具体量化方法未指定）	很活跃（下载量极高；多语言覆盖广）	https://huggingface.co/facebook/mms-1b-all

模型/系列	多语言与方言支持	在线/流式推理能力	推理延迟与吞吐	是否支持量化/蒸馏	社区活跃度与维护状态	关键链接（代码/示例）
Paraformer-large	中文优先；工具链强调时间戳/热词/部署模块能力（工具包论文/文档）	工程上可做流式/离线服务化（工具链提供runtime/ONNX/TensorRT等），具体“流式ASR”能力视所选模型而定（未指定）	模型卡称并行生成可把云端识别机器成本降低近10×（相对描述，基准未指定）	ONNX runtime 示例含 <code>quantize=True</code> ；工具链亦支持TensorRT 等	活跃（仓库star高、issue活跃；模型与脚本更新频繁）	https://github.com/modelscope/FunASR ； https://huggingface.co/funasr/Paraformer-large
WeNet (U2++)	中文生态成熟（公开集上有recipe与CER报告）；可扩展到其他语言（未指定）	以生产化与流式为卖点（仓库定位）；具体流式策略/延迟需结合runtime配置（未指定）	未指定	未指定（可导出到ONNX/sherpa-onnx生态，但量化/蒸馏需另查）	活跃（生产化定位、文档与recipe完整）	https://github.com/wenet-e2e/wenet
Canary-1B-v2	多语（25欧语）；自动标点/时间戳（模型页）	NeMo 文档明确支持 chunked 与 streaming inference（spotlight 模型章节）	未指定（模型页给“更快”相对描述，但本报告不补具体 RTF）	未指定	活跃（NVIDIA 发布、NeMo 文档更新）	https://docs.nvidia.com/nemo-framework/user-guide/latest/nemotoolkit/asr/models.html
Nemotron-ASR-Streaming	英文	原生流式：cache-aware streaming、无重叠计算（模型卡）	强调低延迟/高吞吐，但该模型卡片段未公开具体 ms/RTF 数值	未指定	新近发布（模型卡写明 2026-03-12 发布）	https://build.nvidia.com/nvidia/nemotron-asr-streaming/modelcard

与 SpeakSure++（PDF）需求的匹配解读

时间戳输出是 PDF 中明确需求（用户PDF，第3页）。从模型族特性看：

- Whisper 原生支持“分段时间戳/长音频分段算法”（生态中可继续做更细粒度对齐），且 SpeakSure++ 已在用，迁移成本最低。²⁶
- FunASR Paraformer 生态强调时间戳预测与部署模块（在工具链/论文中被作为特色能力之一），若你们后续需要“热词/标点/VAD 一体化服务”会更顺手。²⁷
- WeNet 的优势在“工程化与生产/流式栈”，适合为 PDF 中“未来实时分析”预留路线，但需要你们接受不同于 Whisper 的训练/解码管线与输出后处理（如 CTC/attention rescoring、LM 融合等）。²⁸
- NVIDIA NeMo（Canary/Nemotron）适合“原生流式+时间戳/标点”的需求，但其语言覆盖以英文/欧语为主，对中文 SpeakSure++ 是否必要取决于你们业务语言分布（PDF未指定）。²⁹

适合微调的公开语音数据集

本节列出更偏“可用于监督微调 ASR”的公开数据集（中文优先）。PDF 未点名任何公开 ASR 数据集，因此“是否在PDF中提及”均为“否”。

数据集对比表

数据集名称	是否在 PDF 中提及	来源/下载链接（URL用代码表示）	许可	语种	时长	标注类型（逐字/时间戳/话者标签）	音频格式
AISHELL-1	否	https://www.openslr.org/33/	Apache 2.0	普通话	178h (train 150h/ dev 10h/ test 5h 等)	逐字转写（句子级）	16kHz（文档写“down to 16kHz”

数据集名称	是否在PDF中提及	来源/下载链接（URL用代码表示）	许可	语种	时长	标注类型（逐字/时间戳/话者标签）	音频格式
WenetSpeech	否	https://www.openslr.org/121/	CC BY 4.0	中文（多领域）	10,000+ h (名称与描述强调规模)	逐字转写（包含弱标注/多源构建，粒度依官方切分）	未指定
Common Voice zh-CN（及中文相关方言子集）	否	https://huggingface.co/datasets/mozilla-foundation/common_voice_17_0 （示例）	CC0（“You can copy/modify/distribute...”）；但有使用/分发约束（不鼓励再托管、禁止识别说话人身份等）	zh-CN（亦有其他中文变体/方言，具体以版本为准）	datasheet: zh-CN total 1073.77h, validated 239.14h（版本口径）	逐字转写（句子级）；无原生时间戳/说话人标签（未指定）	未指定
Primewords Chinese Corpus Set 1	否	https://www.openslr.org/47/	CC BY-NC-ND 4.0	普通话	100h	逐字转写（句子级；提供转写/映射文件）	未指定

数据集名称	是否在PDF中提及	来源/下载链接 (URL用代码表示)	许可	语种	时长	标注类型 (逐字/时间戳/话者标签)	音频格式
ST-CMDS (Chinese Mandarin Speech Dataset)	否	https://www.openslr.org/38/	CC BY-NC-ND 4.0	普通话	102h	逐字转写 (句子级)	16kHz/16bit (文档描述)
MAGICDATA-RAMC (Mandarin Chinese Conversational Speech)	否	https://www.openslr.org/123/	CC BY-NC-ND 4.0	普通话	180h	逐字转写 (会话)	未指定
AISHELL-4 (Meeting)	否	https://www.openslr.org/111/	Apache 2.0	普通话会议	120h	含多通道音频与标注 (会议转写; 是否含说话人标签/时间戳以主页为准)	未指定
AliMeeting	否	https://www.openslr.org/119/	CC BY-SA 4.0	普通话会议	118.75h	会议转写 (多通道; 细粒度标签以主页为准)	16kHz/16bit (描述)
MAGICDATA Mandarin Chinese Read Speech Corpus	否	https://www.openslr.org/68/	CC BY-NC-ND 4.0	普通话	755h	逐字转写 (朗读)	未指定
THCHS-30	否	https://www.openslr.org/18/	Apache 2.0	普通话	30h (经典小数据)	逐字转写 (句子级)	未指定

数据集名称	是否在 PDF 中提及	来源/下载链接 (URL用代码表示)	许可	语种	时长	标注类型 (逐字/时间戳/话者标签)	音频格式
Aidatang_200zh (注意: 资源撤回)	否	<code>https://www.openslr.org/62/</code>	CC BY-NC-ND 4.0	普通话	200h	逐字转写 (句子级)	未指定

许可风险提示 (与业务落地强相关): 多个中文语音集采用 **CC BY-NC-ND 4.0** (非商用 + 禁止演绎/改作), 会显著限制商业产品化与再分发/派生数据发布; Common Voice 虽为 CC0, 但 datasheet 对使用方式提出约束 (如禁止识别说话人身份、反对再托管等)。⁴¹

推荐微调策略与示例脚本

本节给出“只做微调”的策略建议, 并提供至少 3 个可直接执行/改造的示例命令。若 SpeakSure++ 的目标是“提升中文转写准确率、保留犹豫/填充词、并输出可对齐时间戳”, 则应优先围绕: **文本规范化策略一致性、小数据防过拟合、时间戳/对齐链路稳定性、解码器与外部 LM 融合 (针对 CTC/两段式模型)**。

通用微调策略要点

学习率与训练步数: 不同架构差异较大, 应优先参考各自官方脚本的默认/示例值, 而非“一把梭”。例如: Whisper 的公开微调设置中, 峰值学习率常见在 `1e-5` 量级, 且论文示例以 3 epochs 在多卡 V100 上训练 (具体设置依实现)。⁴²

Transformer 官方 CTC 微调示例 (XLSR) 使用 `learning_rate=3e-4` 并配合冻结 feature encoder 与 gradient checkpointing。⁴³

FunASR Paraformer 的示例 finetune 脚本设置 `optim_conf.lr=0.0002`, 并给出 `max_epoch=50` (示例值, 不代表最佳)。⁴⁴

冻结层与参数高效微调 (PEFT/Adapter):

- 小数据 (例如 <10h) 优先考虑冻结底层声学特征抽取部分, 只训练上层/Adapter/LoRA, 以减少过拟合与显存压力 (PDF 未指定数据规模)。Transformers 的 CTC 示例显式启用 `--freeze_feature_encoder`。⁴³
- PEFT 的目的在于只训练少量附加参数以降低计算与存储成本; 其对大模型微调尤为关键。⁴⁵
- Whisper 社区活动文档也提供了在 V100/A100 上的 batch/accum 配置与“节省显存技巧” (如 Adam 8bit、gradient checkpointing 等) 供工程落地。⁴⁶

增量训练 (curriculum / staged fine-tune):

建议按“容易→困难”增量: 先用干净朗读 (AISHELL-1/Primewords) 稳定 CER, 再混入会话/会议 (MAGICDATA-RAMC、AliMeeting) 补齐犹豫与口语现象 (PDF 未指定你们的目标域分布)。⁴⁷

数据增强：

Whisper 论文中提到使用 SpecAugment 等正则方法（作为训练改进手段之一），而 WeNet recipe 与模型卡也经常使用 speed perturb/dither 等增强来提升鲁棒性；微调阶段可以将这些增强“轻量化”地保留。 48

CTC/LM 融合与解码器调整：

如果选用 WeNet/CTC 系（Wav2Vec2、WavLM、MMS），在中文场景常见做法是：

- 先用 CTC prefix beam search 得到候选，再做 attention rescoring / LM rescoring；WeNet aishell recipe 显示 LM+attention rescoring 能带来 CER 改善。 49
- 对于 Seq2Seq（Whisper、Canary），重点在生成参数（beam、长度惩罚、语言 token）与文本规范化（大小写/标点策略）一致性；Whisper 社区活动文档强调“训练文本是否保留大小写/标点”会影响 WER/CER 与可用性，并给出可切换策略。 50

示例微调命令与脚本

以下示例均是“在预训练模型上继续训练”的微调范式，不涉及从头训练。

示例一：Transformers 微调 Whisper (Seq2Seq)

来自 Transformers 官方 speech-recognition 示例 README 的 Whisper 微调命令框架（可改为中文数据集，如 AISHELL/zh-CN Common Voice）。 43

```
# 以 Transformers 官方脚本为骨架：run_speech_recognition_seq2seq.py
# 关键点：--learning_rate 通常在 1e-5 量级（Whisper 常见设置），并设置 language/task token
# 说明：示例中用 Common Voice；你可以替换为 AISHELL-1 等自建 dataset loader

python run_speech_recognition_seq2seq.py \
  --model_name_or_path="openai/whisper-small" \
  --dataset_name="mozilla-foundation/common_voice_11_0" \
  --dataset_config_name="hi" \
  --language="hindi" \
  --task="transcribe" \
  --train_split_name="train+validation" \
  --eval_split_name="test" \
  --max_steps="5000" \
  --output_dir="./whisper-small-ft" \
  --per_device_train_batch_size="16" \
  --gradient_accumulation_steps="2" \
  --per_device_eval_batch_size="16" \
  --learning_rate="1e-5" \
  --warmup_steps="500" \
  --eval_strategy="steps" \
  --eval_steps="1000" \
  --save_steps="1000" \
  --generation_max_length="225" \
  --max_duration_in_seconds="30" \
  --gradient_checkpointing \
  --fp16 \
  --do_train --do_eval
```

训练耗时参考：同一 README 给出“单 V100 上 Whisper-small 5000 steps 约 8 小时”的量级信息，可用来把“数据规模→步数→耗时”映射到你们的硬件环境（PDF 未指定硬件）。 43

示例二：Transformers 微调 XLSR/Wav2Vec2 (CTC)

Transformers 官方给出 XLSR-Wav2Vec2 的 CTC 微调命令，并明确“单 V100 约 1h20m、8×V100 约 18m”的示例耗时，以及冻结 feature encoder、启用 checkpointing 等关键开关。 43

```
python run_speech_recognition_ctc.py \
  --dataset_name="mozilla-foundation/common_voice_17_0" \
  --model_name_or_path="facebook/wav2vec2-large-xlsr-53" \
  --dataset_config_name="tr" \
  --output_dir="./wav2vec2-ft-demo" \
  --num_train_epochs="15" \
  --per_device_train_batch_size="16" \
  --gradient_accumulation_steps="2" \
  --learning_rate="3e-4" \
  --warmup_steps="500" \
  --eval_strategy="steps" \
  --save_steps="400" \
  --eval_steps="100" \
  --freeze_feature_encoder \
  --gradient_checkpointing \
  --fp16 \
  --do_train --do_eval
```

若用于中文：需要将词表构建/字符清理规则改为中文字符集（或改用 BPE/字词混合方案），并在 CER 上评测（PDF 未指定你们内部评测口径）。

示例三：FunASR Paraformer 微调脚本结构 (torchrun)

FunASR 提供了 Paraformer 的 finetune.sh 示例，包含：模型下载、 scp2jsonl 数据准备、torchrun 启动、max_epoch 与学习率等关键参数。 51

```
# 关键内容摘取并做可读化整理（以官方脚本为准）
# 原始脚本位置：
# https://github.com/modelscope/FunASR/blob/main/examples/industrial_data_pretraining/
# paraformer/finetune.sh

export CUDA_VISIBLE_DEVICES="0,1"
gpu_num=2

model_name_or_model_dir="iic/speech_paraformer-large_asr_nat-zh-cn-16k-common-vocab8404-
pytorch"
train_data=".../train.jsonl"
val_data=".../val.jsonl"

torchrun \
  --nproc_per_node $gpu_num \
```

```

../../funasr/bin/train_ds.py \
++model="{model_name_or_model_dir}" \
++train_data_set_list="{train_data}" \
++valid_data_set_list="{val_data}" \
++dataset="AudioDataset" \
++dataset_conf.batch_type="token" \
++dataset_conf.batch_size=6000 \
++train_conf.max_epoch=50 \
++optim_conf.lr=0.0002 \
++output_dir="./outputs"

```

该脚本本质是“继续训练”（fine-tune），无需从头训练。其批大小以 token 为单位、epoch=50 等设置可能更偏“工业数据+长训”，在小数据集上应下调 epoch 并加正则/冻结策略（PDF未指定你们数据规模）。 44

示例四：NVIDIA NeMo 微调（FastConformer/Parakeet Hybrid 示例）

NVIDIA Riva 文档给出使用 `speech_to_text_finetune.py` + Hydra config 微调 Parakeet-Hybrid 的命令示例（该示例仅为 1 epoch 演示，真实训练需增大 epoch）。 52

```

# 文档示例：使用 speech_to_text_finetune.py + 预训练模型初始化
python NeMo/examples/asr/speech_to_text_finetune.py \
--config-path="../../asr/conf/fastconformer/hybrid_transducer_ctc/" \
--config-name=fastconformer_hybrid_transducer_ctc_bpe \
+init_from_pretrained_model=stt_en_fastconformer_hybrid_large_pc \
++model.train_ds.manifest_filepath="train_manifest.json" \
++model.validation_ds.manifest_filepath="test_manifest.json" \
++trainer.devices=1 \
++trainer.max_epochs=1 \
++trainer.precision=bf16 \
++model.optim.name="adamw" \
++model.optim.lr=0.1

```

注意：该学习率数值来自教程演示配置，不应不加验证地直接迁移到中文任务；但它提供了 NeMo 体系“如何用预训练模型初始化 + 替换 manifest + 训练导出”的最短路径（PDF未指定你们是否采用 NeMo/Riva）。 53

微调工作流程图（Mermaid）

flowchart TD

```

A[需求与约束确认\n(PDF: Whisper + 时间戳; 未来实时)] --> B[许可审查\n模型/数据集/输出分发]
B --> C[选择基座模型\nWhisper / WeNet / FunASR / CTC系]
C --> D[选数据集与划分\n干净朗读 + 会话/会议 + 口音]
D --> E[数据处理\n重采样/切分/文本规范化/过滤]
E --> F[微调配置\nLR/冻结层/LoRA或全参/增强]
F --> G[训练与评测\nCER/WER + 关键现象(填充词/停顿)]
G --> H[解码与后处理\nCTC+LM/标点/大小写/时间戳对齐]

```

H --> I[部署与监控\n离线批处理/分块/流式(可选)]
I --> J[回归测试\n跨场景/跨说话人/长音频]

资源估算、风险与注意事项

资源估算方法与参考数

存储估算（16kHz/16bit/mono WAV 的量级）

若按 16kHz、16bit、单声道 WAV 粗略估算，**每小时音频约 115MB**（仅音频，不含特征/缓存）。因此：

- 10h $\approx$ 1.15GB
- 200h $\approx$ 23GB
- 1000h $\approx$ 115GB

这能帮助你们规划“原始音频 + 处理中间件 + 训练缓存”的存储上限（PDF未指定存储预算）。

Whisper 微调的公开参考配置（可直接用于耗时/显存标尺）

- Transformers 官方示例：Whisper-small 在单 V100 上 5000 steps 约 8 小时（示例任务）。⁴³
- Hugging Face Whisper fine-tuning 活动文档给出 V100/A100 上不同模型的 batch/accum 与 step 速度（s/it），可用于把“计划 steps $\rightarrow$ wall time”换算到你们硬件。⁴⁶
- Interspeech 2025 Whisper 微调实验：Whisper-large-v2/v3 在 8 $\times$ V100 16GB、FP16、Deepspeed stage 2、gradient checkpointing 下训练 3 epochs。⁵⁴

小/中/大数据集的“工程化定义”（估算，PDF未指定）

为便于落地，本报告采用常见定义（可按你们真实数据调整）：

- 小： ≤ 10 h 标注音频（快速对齐业务域）
- 中：50–200h（可做稳定域适配）
- 大： ≥ 1000 h（更像二次预训练/大域适配，成本高）

许可、隐私、偏差与过拟合风险

许可合规：

- 多个中文语音集（ST-CMDS、Primewords、MagicData、Aidatatang）使用 CC BY-NC-ND 4.0：限制商业用途并禁止演绎/改作，可能与“可商用模型微调+部署”冲突。⁵⁵
- Common Voice 为 CC0，但 datasheet 对再托管与“识别说话人身份”有明确警示，仍需纳入隐私与使用条款审计。⁵⁶
- FunASR 代码为 MIT，但部分预训练模型权重可能受“Model License Agreement”单独约束；同一生态下不同权重的 license 可能不一致，务必逐一核查。⁵⁷

隐私与数据治理（PDF未指定）：

如果你们会引入业务音频（面试/会议），应在数据入库前完成：脱敏、最小化留存、访问审计、以及“训练集/评测集不可交叉泄漏”的流程隔离。

偏差与公平性：

众包数据（如 Common Voice）带来口音覆盖，但文本质量不一；工业/朗读数据（AISHELL-1、Primewords）偏“干净朗读”，可能导致会话场景（犹豫/重叠说话）适配不足。⁵⁸

过拟合与标签质量：

小数据微调往往出现 CER/WER 下降但“关键现象”（如填充词、犹豫音）被模型删除/规范化的问题（PDF 未指定你们是否将这些现象纳入评价）。建议把“填充词召回率、长停顿对齐误差”加入验收指标，并在微调时保留原始口语转写风格。

实施优先级、推荐组合与短期行动清单

推荐组合（按易用性与效果综合排序）

下列组合均满足“只做微调、不从头训练”。“是否中文优先/是否流式”与 SpeakSure++ 未来路线相关，PDF 未指定具体上线形态，因此给出可选梯度。

组合一：Whisper-small/medium + 中文公开集（AISHELL-1 + 会话补充）+ PEFT/LoRA

优点：与 SpeakSure++ 现有 ASR Agent 一致（Whisper），改动最小；Whisper 微调与资源配置公开资料丰富；可直接把“时间戳输出”保持在同一风格（PDF 硬需求）。⁵⁹

数据建议：AISHELL-1 打底 + MAGICDATA-RAMC 或 AliMeeting 补口语/会议（许可需审查）。⁴⁷

组合二：FunASR Paraformer-large（含 VAD/标点生态）+ 业务域数据微调

优点：中文导向、并行推理效率高；工具链提供服务化与 ONNX/量化参数入口，适合做“长音频+标点+时间戳/热词”一体化工程（具体能力依模型而定）。⁶⁰

注意：需单独核查所选权重的 license（框架 MIT ≠ 权重许可一致）。⁶¹

组合三：WeNet U2++/Conformer + WenetSpeech/AISHELL 系列做域适配（为未来流式做准备）

优点：生产化/流式导向；AISHELL recipe 给出 LM+rescoring 等解码组合与 CER 结果，有利于把“解码器/LM”做成可解释可控模块。⁶²

代价：训练/解码管线与 Whisper 不同，系统集成成本更高（PDF 未指定你们是否愿意切换）。

组合四：MMS（mms-1b-all）/XLSR-53 + Common Voice zh-CN 做口音/方言补强（CTC+LM）

优点：多语/多方言覆盖广；适合补齐长尾口音。⁶³

限制：MMS 为 CC BY-NC 4.0，若商业化需要谨慎。⁶⁴

组合五：若未来“英文实时字幕/流式”优先：Nemotron-ASR-Streaming（英文）+ 现有中文链路并行

优点：原生 cache-aware streaming RNNT，定位低延迟与高吞吐；模型卡给出架构与训练集规模信息。¹⁹

限制：英文限定；license 为 NVIDIA Open Model License Agreement；是否适合你们业务语言分布取决于实际需求（PDF 未指定）。¹⁹

短期可执行行动清单

- 从《SpeakSure++》现有 ASR Agent 出发，明确“时间戳粒度验收标准”（段级/词级/句级）与 ASR 微调目标（仅 CER/WER 下降？还是必须保留填充词/犹豫音）。粒度在 PDF 中未指定，可作为第一项需求补齐（用户 PDF，第3页）。
- 先用 AISHELL-1 + Whisper-small 复现 Transformers Whisper 微调脚手架（示例一），把数据管线（重采样、切分、文本规范化、CER 评测）跑通，再加入会话数据（MAGICDATA-RAMC / AliMeeting）做第二阶段域适配。⁶⁵

- 建立“许可白名单”：优先 Apache 2.0 / CC BY / CC0；对 CC BY-NC-ND、CC BY-NC、CC BY-SA 做产品化风险分级与替代方案（如仅用于研究/内部评测）。⁶⁶
- 若你们的“未来实时分析”（用户PDF，第12页）确实要落地，尽早做一条“流式原型链路”：用 WeNet 或 NeMo 的 streaming/chunked inference 在 1-2 个代表性场景音频上验证端到端延迟与对齐稳定性，再决定是否迁移主链路。⁶⁷
- 为 SpeakSure++ 的“不确定性分析”增加 ASR 侧的“质量分层”日志：记录每段音频的 CER/WER、OOV/热词命中率、填充词召回率、时间戳对齐误差，用于定位微调收益是否真实反映在下游分析指标上（PDF 未指定该闭环，目前建议补齐）。
- 选定 1 个参数高效方案（LoRA 或 Adapter）作为默认微调基线，并在同一数据上与全参微调做 A/B（至少比较：最终 CER/WER、训练时长、显存峰值、推理延迟/吞吐的变化）。⁶⁸

¹ ⁵ ²⁰ <https://github.com/openai/whisper/blob/main/model-card.md>

<https://github.com/openai/whisper/blob/main/model-card.md>

² ⁴⁹ <https://github.com/wenet-e2e/wenet/blob/main/examples/aishell/s0/README.md>

<https://github.com/wenet-e2e/wenet/blob/main/examples/aishell/s0/README.md>

³ ⁴ ¹³ ³⁰ ⁴⁷ ⁶⁵ <https://www.openslr.org/33/>

<https://www.openslr.org/33/>

⁶ ¹⁴ ²³ ⁶⁰ <https://huggingface.co/funasr/Paraformer-large>

<https://huggingface.co/funasr/Paraformer-large>

⁷ ²¹ <https://huggingface.co/distil-whisper/distil-large-v2>

<https://huggingface.co/distil-whisper/distil-large-v2>

⁸ ¹² ⁶³ ⁶⁴ <https://huggingface.co/facebook/mms-1b>

<https://huggingface.co/facebook/mms-1b>

⁹ <https://huggingface.co/facebook/wav2vec2-large-xlsr-53>

<https://huggingface.co/facebook/wav2vec2-large-xlsr-53>

¹⁰ ³⁹ <https://www.openslr.org/18/>

<https://www.openslr.org/18/>

¹¹ <https://huggingface.co/microsoft/wavlm-large/blame/41f0899a40d312edfdd394e621cfaddb57de6801/README.md>

<https://huggingface.co/microsoft/wavlm-large/blame/41f0899a40d312edfdd394e621cfaddb57de6801/README.md>

¹⁵ ³¹ <https://www.openslr.org/121/>

<https://www.openslr.org/121/>

¹⁶ ²⁴ ²⁸ ⁶² ⁶⁷ <https://github.com/wenet-e2e/wenet>

<https://github.com/wenet-e2e/wenet>

¹⁷ ³⁸ https://github.com/double22a/speech_dataset

https://github.com/double22a/speech_dataset

¹⁸ <https://huggingface.co/nvidia/canary-1b-v2>

<https://huggingface.co/nvidia/canary-1b-v2>

¹⁹ <https://build.nvidia.com/nvidia/nemotron-asr-streaming/modelcard>

<https://build.nvidia.com/nvidia/nemotron-asr-streaming/modelcard>

²² <https://huggingface.co/facebook/mms-1b-all>

<https://huggingface.co/facebook/mms-1b-all>

25 29 <https://docs.nvidia.com/nemo-framework/user-guide/latest/nemotoolkit/asr/models.html>
<https://docs.nvidia.com/nemo-framework/user-guide/latest/nemotoolkit/asr/models.html>

26 <https://github.com/openai/whisper>
<https://github.com/openai/whisper>

27 https://www.isca-archive.org/interspeech_2023/gao23g_interspeech.pdf
https://www.isca-archive.org/interspeech_2023/gao23g_interspeech.pdf

32 56 58 <https://datacollective.mozillafoundation.org/datasets/cmn3iaztg00e4mb070uvufz7q>
<https://datacollective.mozillafoundation.org/datasets/cmn3iaztg00e4mb070uvufz7q>

33 <https://www.openslr.org/47/>
<https://www.openslr.org/47/>

34 41 55 66 <https://openslr.org/38/>
<https://openslr.org/38/>

35 <https://www.openslr.org/123/>
<https://www.openslr.org/123/>

36 <https://www.openslr.org/111/>
<https://www.openslr.org/111/>

37 <https://www.openslr.org/119/>
<https://www.openslr.org/119/>

40 <https://www.openslr.org/62/>
<https://www.openslr.org/62/>

42 54 https://www.isca-archive.org/interspeech_2025/zhuang25_interspeech.pdf
https://www.isca-archive.org/interspeech_2025/zhuang25_interspeech.pdf

43 <https://github.com/huggingface/transformers/blob/main/examples/pytorch/speech-recognition/README.md>
<https://github.com/huggingface/transformers/blob/main/examples/pytorch/speech-recognition/README.md>

44 51 https://github.com/alibaba-damo-academy/FunASR/blob/main/examples/industrial_data_pretraining/paraformer/finetune.sh
https://github.com/alibaba-damo-academy/FunASR/blob/main/examples/industrial_data_pretraining/paraformer/finetune.sh

45 68 <https://github.com/huggingface/peft>
<https://github.com/huggingface/peft>

46 50 <https://github.com/huggingface/community-events/blob/main/whisper-fine-tuning-event/README.md>
<https://github.com/huggingface/community-events/blob/main/whisper-fine-tuning-event/README.md>

48 <https://cdn.openai.com/papers/whisper.pdf>
<https://cdn.openai.com/papers/whisper.pdf>

52 53 <https://docs.nvidia.com/deeplearning/riva/user-guide/docs/tutorials/asr-finetune-parakeet-nemo.html>
<https://docs.nvidia.com/deeplearning/riva/user-guide/docs/tutorials/asr-finetune-parakeet-nemo.html>

57 <https://github.com/modelscope/FunASR/blob/main/LICENSE>
<https://github.com/modelscope/FunASR/blob/main/LICENSE>

⁵⁹ <https://huggingface.co/blog/fine-tune-whisper>

<https://huggingface.co/blog/fine-tune-whisper>

⁶¹ https://github.com/modelscope/FunASR/blob/main/MODEL_LICENSE

https://github.com/modelscope/FunASR/blob/main/MODEL_LICENSE